SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
VARAŽDIN

Luka Gvozdanović Link na video

ANALIZA TRŽIŠTA RABLJENIH VOZILA

PROJEKT

SKLADIŠTA PODATAKA I POSLOVNA INTELIGENCIJA

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU

FAKULTET ORGANIZACIJE I INFORMATIKE

V A R A Ž D I N

Luka Gvozdanović Link na video

Matični broj: 0016154110

Studij: Organizacija poslovnih sustava

ANALIZA TRŽIŠTA RABLJENIH VOZILA

PROJEKT

Mentorica:

mag. educ. inf. Maja Cerjan

Varaždin, lipanj 2026.

Luka Gvozdanović Link na video

Izjava o izvornosti

Izjavljujem da je ovaj projekt izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor potvrdio prihvaćanjem odredbi u sustavu FOI Radovi

Sažetak

U ovom projektu prikazana je analiza tržišta rabljenih vozila, ali uz to i cijeli postupak izrade ove analize. Prvi korak je bio prikupljanje podataka, to jest pronalazak odgovarajućeg skupa podataka. Zatim je bilo potrebno skup podataka očistiti i pripremiti za iduću obradu. Nakon što je skup podataka bio spreman, podaci su se trebali pretvoriti u zvijezda shemu kako bi se mogao napraviti cilj projekta, a to je analiza. Nakon što su podaci uvezeni u alat u kojem se radi analiza, napravljena je početna provjera kako bi se osiguralo da su svi podaci uvezeni pravilno. Prvo je napravljen početni izvještaj zajedno sa 5 izvještaja koji svaki ima svoju temu.

Ključne riječi: kaggle; powerBI; python; obrada podataka; analiza podataka

Sadržaj

1. Uvod 1

2. Korišteni alati 2

3. Prikaz podataka 3

4. Obrada podataka 5

5. Analiza podataka 9

5.1. Uvoz podataka 9

5.2. Izvješća 9

5.2.1. Prodaja po marki vozila 10

5.2.2. Trend prodaje kroz vrijeme 11

5.2.3. Geografska analiza 12

5.2.4. Analiza kupaca 13

5.2.5. Cjenovna analiza 14

6. Zaključak 15

Popis literature 16

Popis slika 17

Popis tablica 18

Popis isječaka koda 19

1. Uvod

Analiza poslovanja važan je dio uspješnog upravljanja svakim poduzećem jer omogućuje **donošenje kvalitetnih poslovnih odluka** temeljenih na **podacima**. Kroz analizu prodaje, kupaca i tržišnih trendova moguće je prepoznati uzorke, prednosti i nedostatke poslovanja te prepoznati prilike za poboljšanje poslovanja.

Tema ovog projekta je **analiza tržišta vozila**. Izrađeno izvješće pruža uvid u prodaju vozila, trendove prodaje kroz vrijeme, geografske karakteristike tržišta, navike kupaca te uspješnost prodavača.

Cilj projekta bio je izraditi **interaktivno poslovno izvješće u alatu Power BI** te primijeniti tehnike vizualizacije podataka kako bi se složeni podaci prikazali na jasan i razumljiv način.

Link na video: https://youtu.be/7UVADcSCC7Y

2. Korišteni alati

Na projektu su se koristila 3 alata ovim redoslijedom: **Kaggle** za dohvaćanje podataka, **Python** za obradu podataka i **Power BI** za izradu izvješća i vizualizaciju.

Kaggle je popularna web stranica za pronalazak različitih skupova podataka koji se često koriste u području strojnog učenja i znanosti o podacima. Na toj platformi pronađen je i odabrani skup podataka korišten u ovom projektu [1]. Nakon pribavljanja podataka bilo ih je potrebno očistiti i pripremiti za daljnju obradu.

Za čišćenje podataka korišten je programski jezik Python zajedno s **bibliotekom Pandas**. Pandas je biblioteka namijenjena radu sa skupovima podataka te pruža brojne funkcionalnosti za analiziranje, čišćenje, istraživanje i manipuliranje podacima [2]. Također, ova biblioteka korištena je i na prethodnim kolegijima pa je njezino korištenje bilo dobro poznato.

Posljednji korišteni alat bio je Power BI, koji služi za vizualizaciju i analizu podataka. Razvio ga je Microsoft, a omogućuje izradu interaktivnih izvješća i preglednih nadzornih ploča koje olakšavaju interpretaciju podataka i donošenje poslovnih odluka [3].

3. Prikaz podataka

Podaci korišteni u ovom projektu preuzeti su s web stranice Kaggle. Naziv odabranog skupa podataka je *Car Sales Report*, kreirano od *Vasu_Avasthi*. Prema informacijama dostupnim na stranici, skup podataka je objavio autor te je posljednji put ažuriran prije dvije godine u odnosu na vrijeme izrade ovog projekta. Autor navodi da se skup podataka može koristiti za različite vrste analiza, uključujući **tržišnu analizu**, **analizu sezonskih obrazaca**, **prediktivnu analizu** te **analizu lanca nabave**. Zbog velikog broja atributa i količine podataka, ovaj skup predstavlja dobru osnovu za istraživanje tržišta vozila i izradu poslovnih izvješća.

Skup podataka ima **16 atributa** i **23906 redova**. Tablica 1 prikazuje osnovne informacije o skupu podataka, dok slika 1 prikazuje prvih nekoliko redaka sirovog skupa podataka.

Tablica 1: Osnovne informacije o skupu podataka

Atribut	**Opis**	**Tip**
Car_id	Identifikator prodaje vozila	object
Date	Datum transakcije prodaje	object
Customer Name	Ime kupca	object
Gender	Spol kupca	object
Annual Income	Godišnji prihod kupca	int64
Dealer_Name	Naziv prodajnog mjesta (dealera)	object
Company	Marka (proizvođač) vozila	object
Model	Model vozila	object
Engine	Vrsta motora vozila	object
Transmission	Vrsta mjenjača vozila	object
Color	Boja vozila	object
Price($)	Prodajna cijena vozila u dolarima	int64
Dealer_No	Identifikator dealera	object
Body Style	Tip karoserije vozila	object
Phone	Telefonski broj kupca	int64
Dealer_Region	Geografska regija prodajnog mjesta	object

	Sale_ID	Date	Customer Name	Gender	Annual Income	Dealer_Name	Company	Model	Engine	Transmission	Color	Price ($)	Dealer_No	Body Style	Phone	Dealer_Region
0	1	1/2/2022	Geraldine	Male	13500	Buddy Storbeck's Diesel Service Inc	Ford	Expedition	DoubleÂ Overhead Camshaft	Auto	Black	26000	06457-3834	SUV	8264678	Middletown
1	2	1/2/2022	Gia	Male	1480000	C & M Motors Inc	Dodge	Durango	DoubleÂ Overhead Camshaft	Auto	Black	19000	60504-7114	SUV	6848189	Aurora
2	3	1/2/2022	Gianna	Male	1035000	Capitol KIA	Cadillac	Eldorado	Overhead Camshaft	Manual	Red	31500	38701-8047	Passenger	7298798	Greenville
3	4	1/2/2022	Giselle	Male	13500	Chrysler of Tri-Cities	Toyota	Celica	Overhead Camshaft	Manual	Pale White	14000	99301-3882	SUV	6257557	Pasco
4	5	1/2/2022	Grace	Male	1465000	Chrysler Plymouth	Acura	TL	DoubleÂ Overhead Camshaft	Auto	Red	24500	53546-9427	Hatchback	7081483	Janesville

Slika 1: Sirovi podaci

4. Obrada podataka

Ovaj skup podataka je zahtijevao dva koraka: **čišćenje** i **pretvorba** u **shemu zvijezda**. Kratki pogled na sirove podatke (slika 1) i već vidimo potrebu za promjenama.

Prva stvar koju je potrebno popraviti je `Car_id`. On je trenutno u string obliku, želimo da glavni id bude u integer obliku. Kako ćemo kasnije cijeli skup podijeliti na više tablica, ovaj id će poslužiti kao glavni id. Dodat ćemo novi stupac `Sale_ID` (ponovo ćemo ga preimenovati kasnije) i zatim ga premjestiti na prvo mjesto i maknuti stupac `Car_id`.

```
df.insert(0, 'Sale_ID', range(1, len(df) + 1))
df.drop(columns=['Car_id'], inplace=True)
```

Isječak koda 1: Dodavanje i brisanje stupaca

Ispisivanjem `df.info()` dobivamo osnovne informacije o samom skupu a sa komandom `df.duplicated()` ispitujemo ima li duplikata.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 23906 entries, 0 to 23905
Data columns (total 16 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Car_id          23906 non-null  object
 1   Date            23906 non-null  object
 2   Customer Name   23905 non-null  object
 3   Gender          23906 non-null  object
 4   Annual Income   23906 non-null  int64
 5   Dealer_Name     23906 non-null  object
 6   Company         23906 non-null  object
 7   Model           23906 non-null  object
 8   Engine          23906 non-null  object
 9   Transmission    23906 non-null  object
 10  Color           23906 non-null  object
 11  Price ($)       23906 non-null  int64
 12  Dealer_No       23906 non-null  object
 13  Body Style      23906 non-null  object
 14  Phone           23906 non-null  int64
 15  Dealer_Region   23906 non-null  object
dtypes: int64(3), object(13)
memory usage: 2.9+ MB
```

Isječak koda 2: Ispis df.info()

```
print("Duplikati:", df.duplicated().sum())

//Duplikati: 0
```

Isječak koda 3: Ispitivanje duplikata

Još jedan trn u oku je ovaj naziv: *DoubleÂ Overhead Camshaft*. Moramo maknuti Â iz naziva kako bi vrijednosti bile ispravne. Koristimo kod koji će zamijeniti, to jest maknuti slovo.

```
df = df.apply(lambda col: col.map(lambda x: x.replace('Â\xa0', ' ').replace('Â ', ' ').strip() if isinstance(x, str) else x))
```

Isječak koda 4: Ispitivanje duplikata

Za ovu analizu nisu nam potrebni stupci `Dealer_No` i `Phone`, tako da se oni neće koristiti u idućem koraku.

Nakon pripreme skupa podataka, pristupilo se izgradnji zvijezda sheme. U prvom koraku kreirane su dimenzijske tablice, a potom i činjenična tablica. U nastavku su prikazani isječci koda korišteni za kreiranje svake dimenzijske tablice, zajedno s prikazom rezultirajuće strukture podataka.

```
dim_car = df[['Company', 'Model', 'Engine', 'Transmission', 'Color', 'Body Style']].drop_duplicates().reset_index(drop=True)
dim_car.insert(0, 'car_id', range(1, len(dim_car) + 1))
print(dim_car.shape)
dim_car.head()
```

Isječak koda 5: Dimenzijska tablica - dim_car

	car_id	Company	Model	Engine	Transmission	Color	Body Style
0	1	Ford	Expedition	Double Overhead Camshaft	Auto	Black	SUV
1	2	Dodge	Durango	Double Overhead Camshaft	Auto	Black	SUV
2	3	Cadillac	Eldorado	Overhead Camshaft	Manual	Red	Passenger
3	4	Toyota	Celica	Overhead Camshaft	Manual	Pale White	SUV
4	5	Acura	TL	Double Overhead Camshaft	Auto	Red	Hatchback

Slika 2: Struktura Dimenzijske tablice dim_car

```
dim_dealer = df[['Dealer_Name', 'Dealer_Region']].drop_duplicates().reset_index(drop=True)
dim_dealer.insert(0, 'dealer_id', range(1, len(dim_dealer) + 1))
print(dim_dealer.shape)
dim_dealer.head()
```

Isječak koda 6: Dimenzijska tablica - dim_dealer

	dealer_id	Dealer_Name	Dealer_Region
0	1	Buddy Storbeck's Diesel Service Inc	Middletown
1	2	C & M Motors Inc	Aurora
2	3	Capitol KIA	Greenville
3	4	Chrysler of Tri-Cities	Pasco
4	5	Chrysler Plymouth	Janesville

Slika 3: Struktura Dimenzijske tablice dim_dealer

```
dim_customer = df[['Customer Name', 'Gender', 'Annual
↪  Income']].drop_duplicates().reset_index(drop=True)
dim_customer.insert(0, 'customer_id', range(1, len(dim_customer) + 1))
print(dim_customer.shape)
dim_customer.head()
```

Isječak koda 7: Dimenzijska tablica - dim_customer

	customer_id	Customer Name	Gender	Annual Income
0	1	Geraldine	Male	13500
1	2	Gia	Male	1480000
2	3	Gianna	Male	1035000
3	4	Giselle	Male	13500
4	5	Grace	Male	1465000

Slika 4: Struktura Dimenzijske tablice dim_customer

```
df['Date'] = pd.to_datetime(df['Date'])

dim_date = df[['Date']].drop_duplicates().reset_index(drop=True)
dim_date.insert(0, 'date_id', range(1, len(dim_date) + 1))
dim_date['year']  = dim_date['Date'].dt.year
dim_date['month'] = dim_date['Date'].dt.month
dim_date['day']   = dim_date['Date'].dt.day
print(dim_date.shape)
dim_date.head()
```

Isječak koda 8: Dimenzijska tablica - dim_date

	date_id	Date	year	month	day
0	1	2022-01-02	2022	1	2
1	2	2022-01-03	2022	1	3
2	3	2022-01-04	2022	1	4
3	4	2022-01-05	2022	1	5
4	5	2022-01-06	2022	1	6

Slika 5: Struktura Dimenzijske tablice dim_date

Za kraj, preostalo je samo kreirati činjeničnu tablicu i spojiti ju sa ostalim dimenzijskim. kreiramo činjeničnu tablicu sa sljedećim kodom, i kao rezultat dobivamo strukturu prikazanu na slici 6. Jedine promjene koje su napravljene je preimenovanje dvaju stupaca: `Sale_ID` i `Price`.

```
F_car =
↪  df.merge(dim_car[['car_id','Company','Model','Engine','Transmission','Color','Body
↪  Style']],
                on=['Company','Model','Engine','Transmission','Color','Body Style'])

F_car = F_car.merge(dim_dealer[['dealer_id','Dealer_Name','Dealer_Region']],
                    on=['Dealer_Name','Dealer_Region'])

F_car = F_car.merge(dim_customer[['customer_id','Customer Name','Gender','Annual
↪  Income']],
                    on=['Customer Name','Gender','Annual Income'])

F_car = F_car.merge(dim_date[['date_id','Date']],
                    on='Date')

F_car_sale = F_car[['Sale_ID','car_id','dealer_id','customer_id','date_id','Price
↪  ($)']].copy()
F_car_sale.rename(columns={'Sale_ID': 'F_car_id', 'Price ($)': 'price'},
↪  inplace=True)
```

Isječak koda 9: Činjenična tablica - fact_sale

	F_car_id	car_id	dealer_id	customer_id	date_id	price
0	1	1	1	1	1	26000
1	2	2	2	2	1	19000
2	3	3	3	3	1	31500
3	4	4	4	4	1	14000
4	5	5	5	5	1	24500
5	6	6	6	6	1	12000

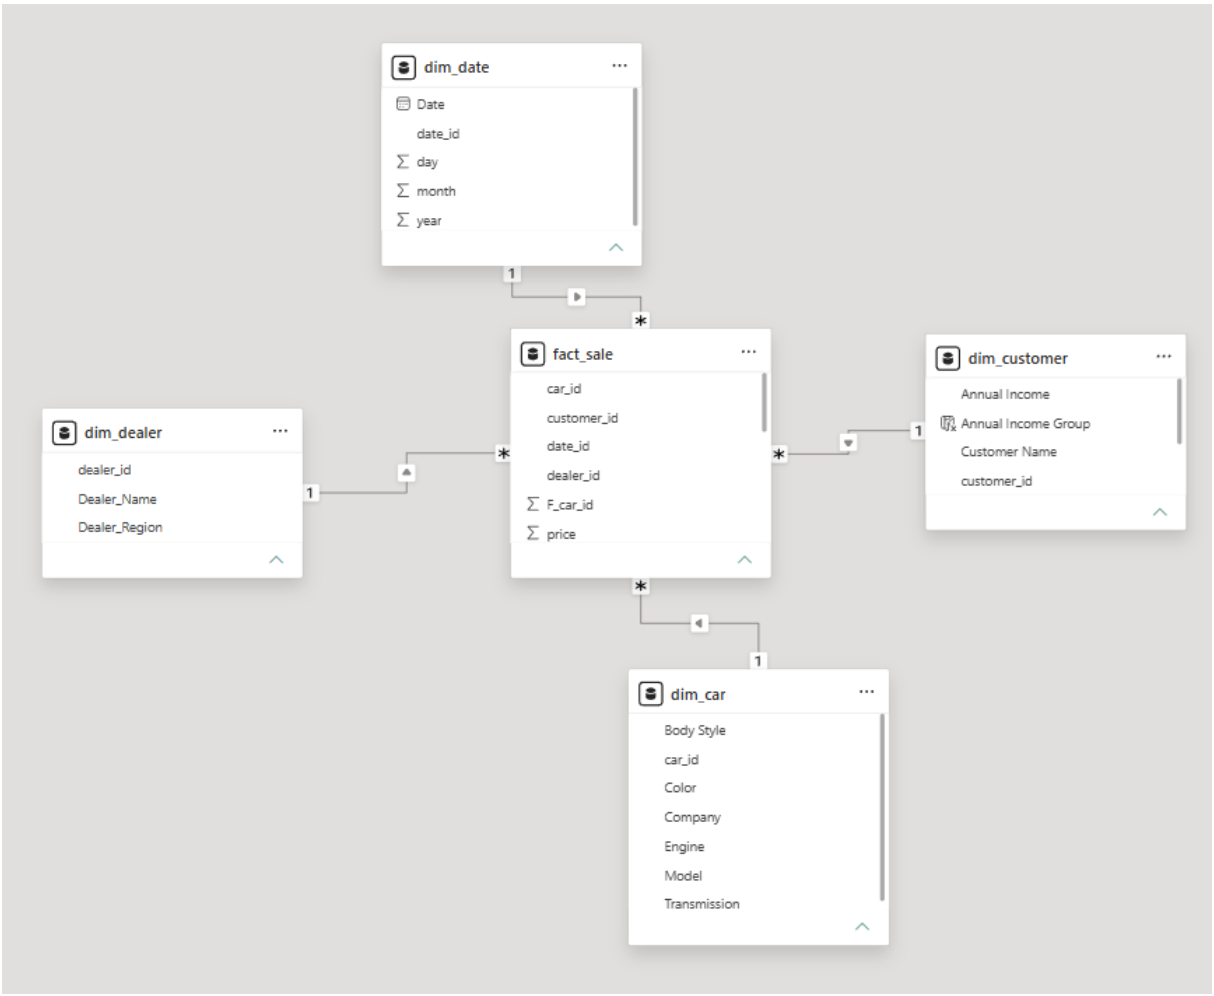
Slika 6: Činjenična tablica

Ovim korakom je završena obrada podataka te su podaci spremni za uvoz u alat Power BI gdje će se provesti analiza podataka.

5. Analiza podataka

5.1. Uvoz podataka

Power BI ima jednostavan uvoz podataka. Koristi se opcija *Get data* i zatim su ponuđene najčešće opcije poput JSON, CSV i slično. Poadci su u CSV obliku pa se bira opcija *Text/CSV*. Zatim ubacujemo tablicu po tablicu u Power BI. Nakon provjere da su svi podaci pravilno uvezeni, provjeravamo strukturu skladišta, slika 7.

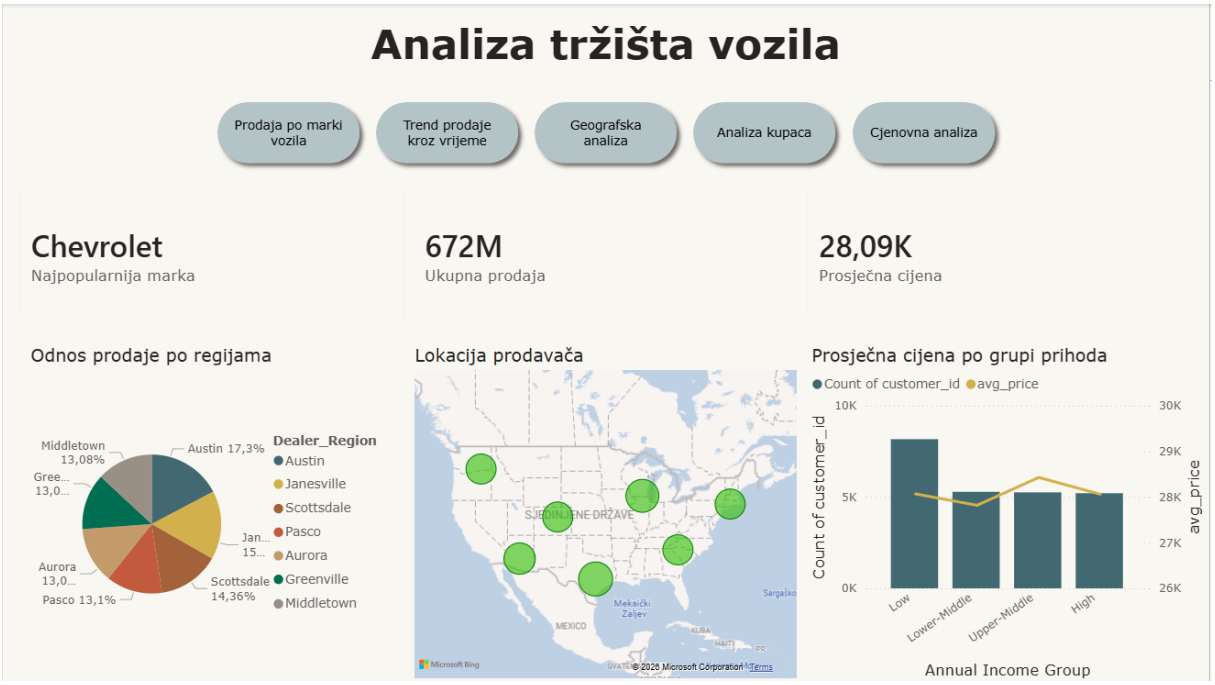


Slika 7: Zvijezda shema u Power BI

Na slici vidimo činjeničnu tablicu u sredini i dimenzijske tablice oko nje, što jasno prikazuje strukturu zvijezda sheme. Na taj način model postaje pregledan, logičan i prikladan za izradu izvještaja i vizualizacija.

5.2. Izvješća

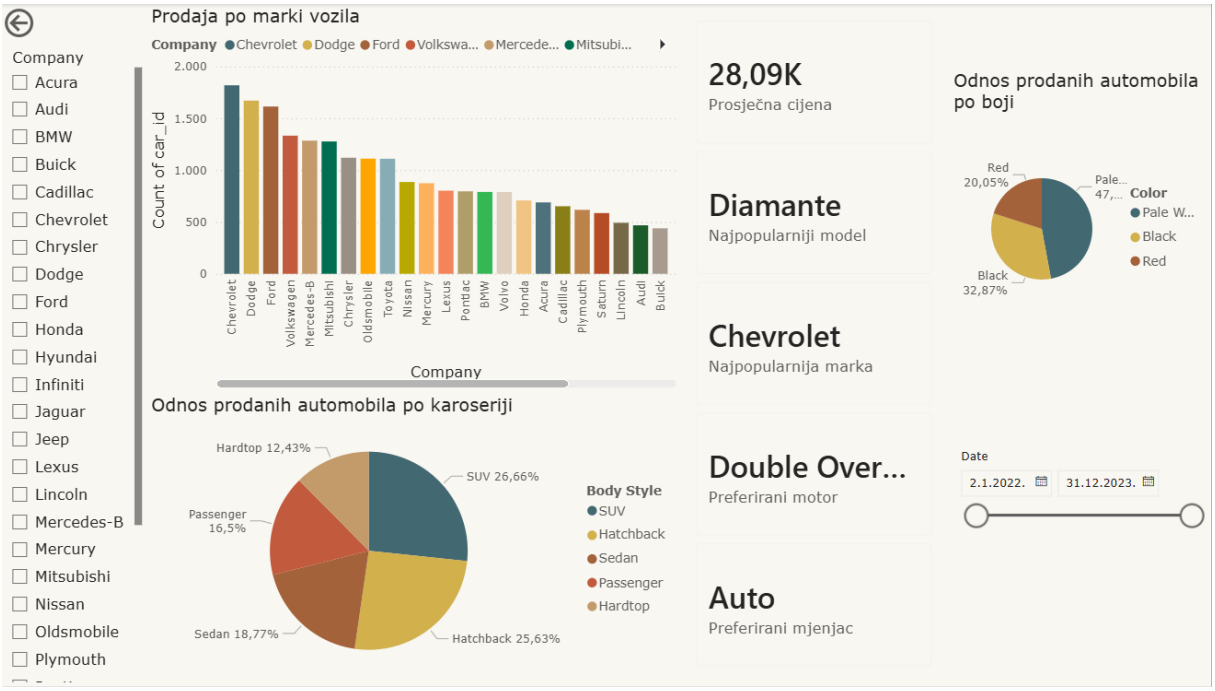
Sljedeći dio je cilj ovog projekta, **izraditi izvješća**. Ovaj projekt sadrži početno izvješće (slika 8) sa navigacijom na **ostalih 5 tematskih izvješća**.



Slika 8: Početno izvješće

Preko početnog izvješća korisnik se može navigirati na ovih 5 izvješća: **Prodaja po marki vozila**, **Trend prodaje kroz vrijeme**, **Geografska analiza**, **Analiza kupaca**, **Cjenovna analiza**.

5.2.1. Prodaja po marki vozila

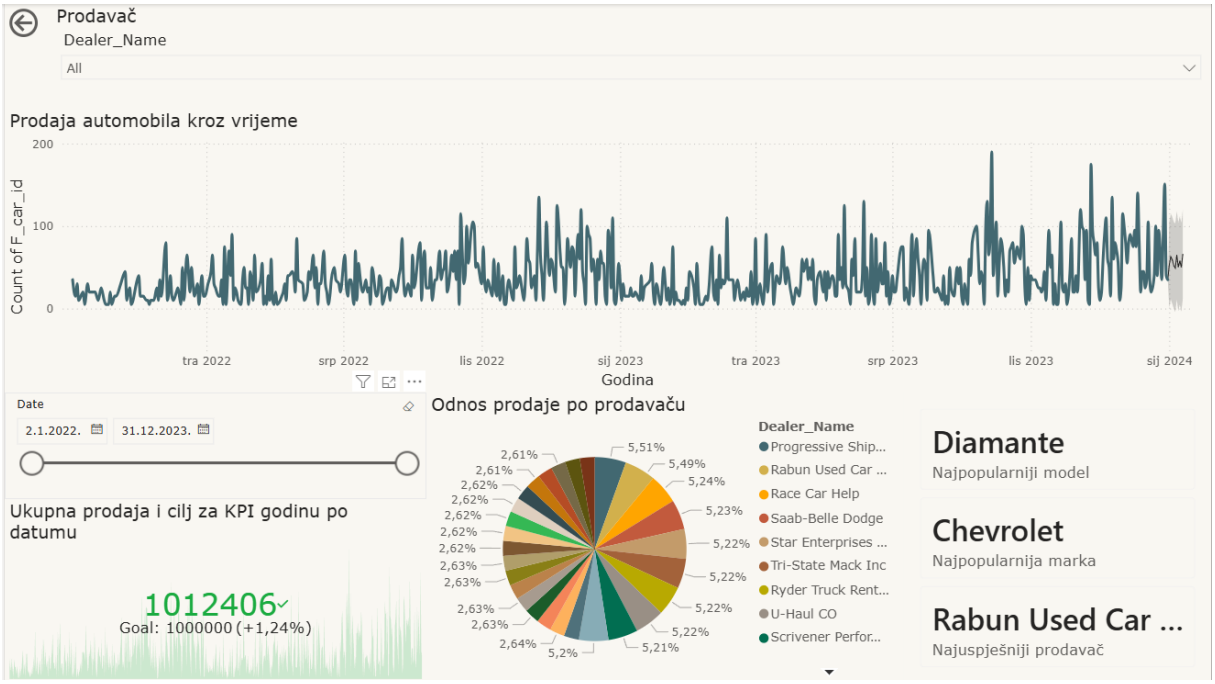


Slika 9: Prodaja po marki vozila

Prvo izvješće prodaja po marki vozila pruža pregled prodaje vozila prema proizvođačima te omogućuje usporedbu popularnosti pojedinih marki. Stupčasti graf prikazuje broj prodanih vozila za svaku marku, dok se pomoću filtra s lijeve strane mogu odabrati pojedine marke za detaljniju analizu. Kružni graf „Odnos prodanih automobila po karoseriji" prikazuje udio prodanih vozila prema tipu karoserije (SUV, sedan i ostale). Na temelju njega moguće je uočiti koje vrste vozila kupci najčešće preferiraju. Drugi kružni graf „Odnos prodanih automobila po boji" prikazuje preferencije pojedinih boja među prodanim vozilima. Kartice koje se protežu od vrha do dna izvješća prikazuju prosječnu cijenu vozila, najpopularniji model, najpopularniju marku, preferirani tip motora i preferirani tip mjenjača. Dodatno, vremenski filtar omogućuje promatranje podataka za odabrano razdoblje.

Rezultat ovog izvješća može poslužiti za **prepoznavanje najtraženijih marki i karakteristika vozila,** kako bi prodavač mogao nabavljati ona vozila koja su tražena.

5.2.2. Trend prodaje kroz vrijeme

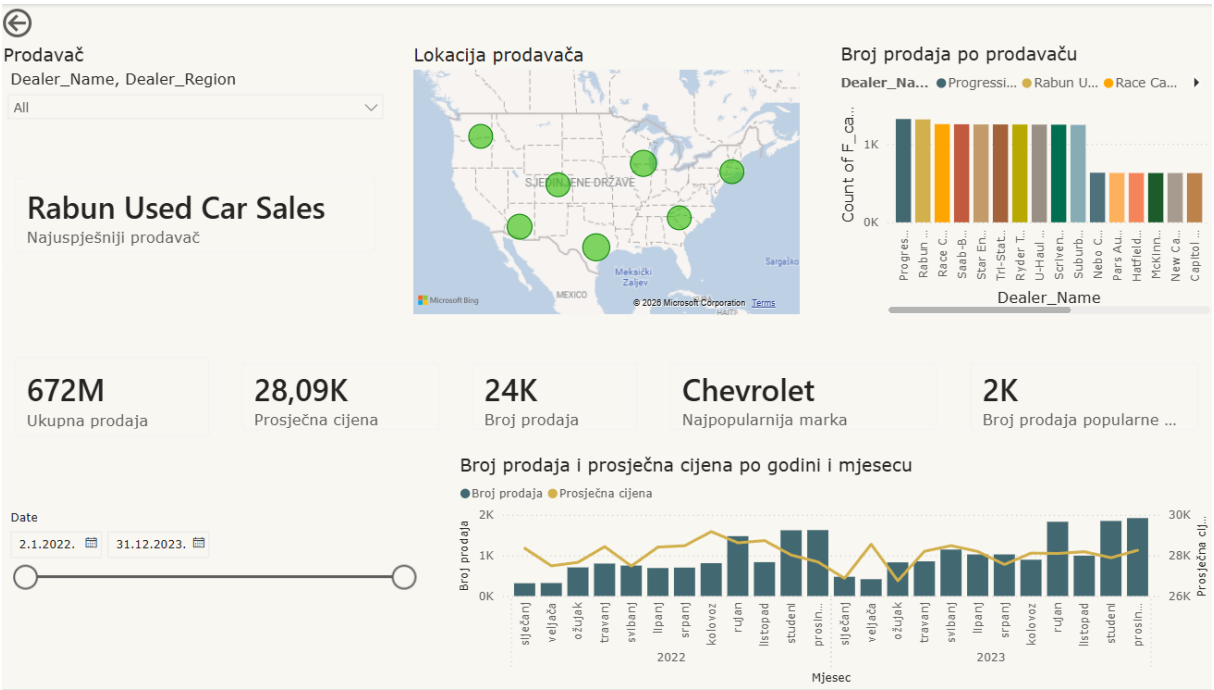


Slika 10: Trend prodaje kroz vrijeme

Sljedeće izvješće, kako mu i ime govori, prikazuje trend prodaje kroz vrijeme. Skroz na vrhu se nalazi izbornik sa svim prodavačkim kućama kako bi se po izboru ostatak izvješća dinamično mijenjao. Graf na gornjoj polovici prikazuje broj prodanih automobila kroz vrijeme, time davajući uvid u uzorak prodaje i sezonske potražnje. Pri samom kraju istog grafa se nalazi i siva zona koja predviđa buduću potražnju/prodaju temeljem na prethodnim podacima. Ovdje se također nalazi vremenski filtar kako bi se dao bolji uvid u određeni vremenski period. Ispod vremenskog filtra se nalazi KPI sa ciljem ukupne prodaje. Kružni graf prikazuje raspodjelu prodaja po svim prodavačima, i na kraju se nalaze kartice sa najpopularnijim modelom, markom i najuspješnijim prodavačem.

Ovom analizom se može dobiti **uvid o sezonskoj potražnji**. Na primjer, rujan ima visoku prodaju automobila, to može sugerirati da osobe kupuju automobile zbog početka srednje škole ili fakulteta.

5.2.3. Geografska analiza

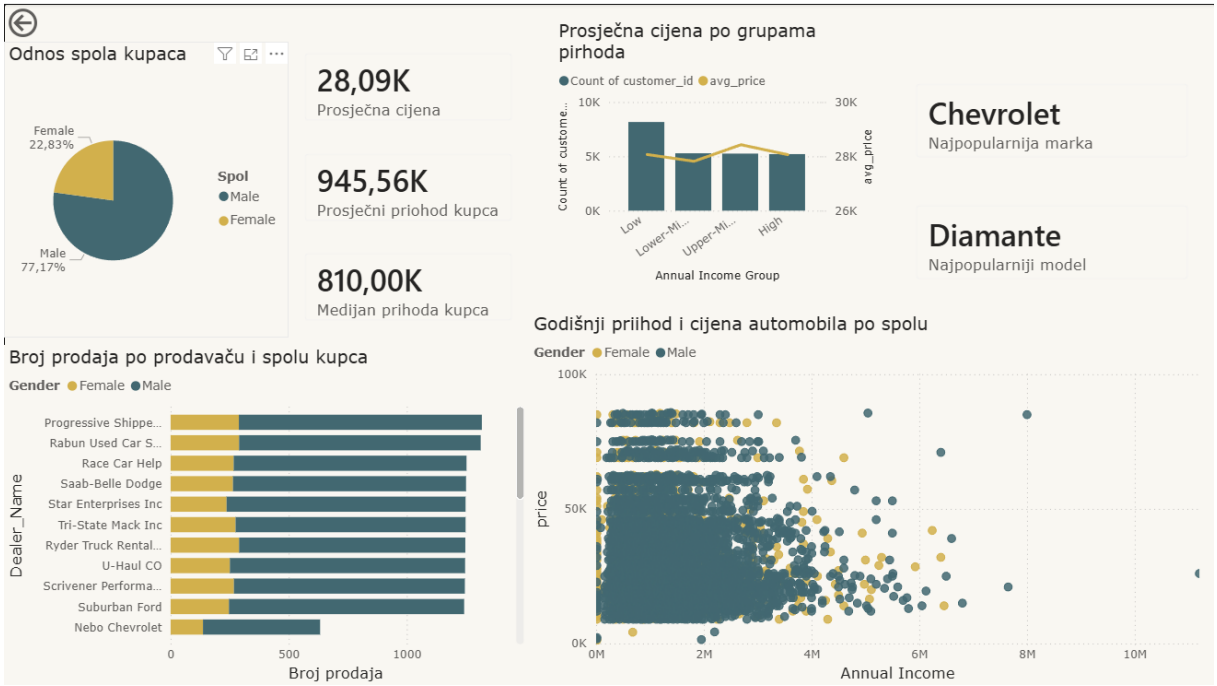


Slika 11: Geografska analiza

Ovo izvješće fokusirano je na analizu uspješnosti prodavača i njihovih prodajnih rezultata. Padajući izbornik omogućuje odabir pojedinog prodavača ili regije, čime se svi prikazani podaci automatski prilagođavaju odabranom filtru. Karta „Lokacija prodavača" prikazuje geografski raspored prodavača po regijama te omogućuje lakše uočavanje područja u kojima se ostvaruje prodaja vozila. Desno od karte, stupčasti graf „Broj prodaja po prodavaču" prikazuje usporedbu prodajnih rezultata između različitih prodavača. Na temelju njega moguće je identificirati najuspješnije i najmanje uspješne prodavače. Kartica „Najuspješniji prodavač" prikazuje prodavača s najvećim brojem ostvarenih prodaja u odabranom razdoblju, dok ostale prikazuju ukupnu vrijednost prodaje, prosječnu cijenu vozila, ukupan broj prodaja, najpopularniju marku vozila te broj prodaja najpopularnije marke. Graf u donjem desnom kutu Broj prodaja i prosječna cijena po godini i mjesecu prikazuje kretanje broja prodaja kroz vrijeme te istovremeno omogućuje usporedbu s prosječnom cijenom vozila.

Ovo izvješće može poslužiti za **praćenje uspješnosti prodavača, usporedbu njihovih rezultata te donošenje odluka vezanih uz prodajne ciljeve**.

5.2.4. Analiza kupaca

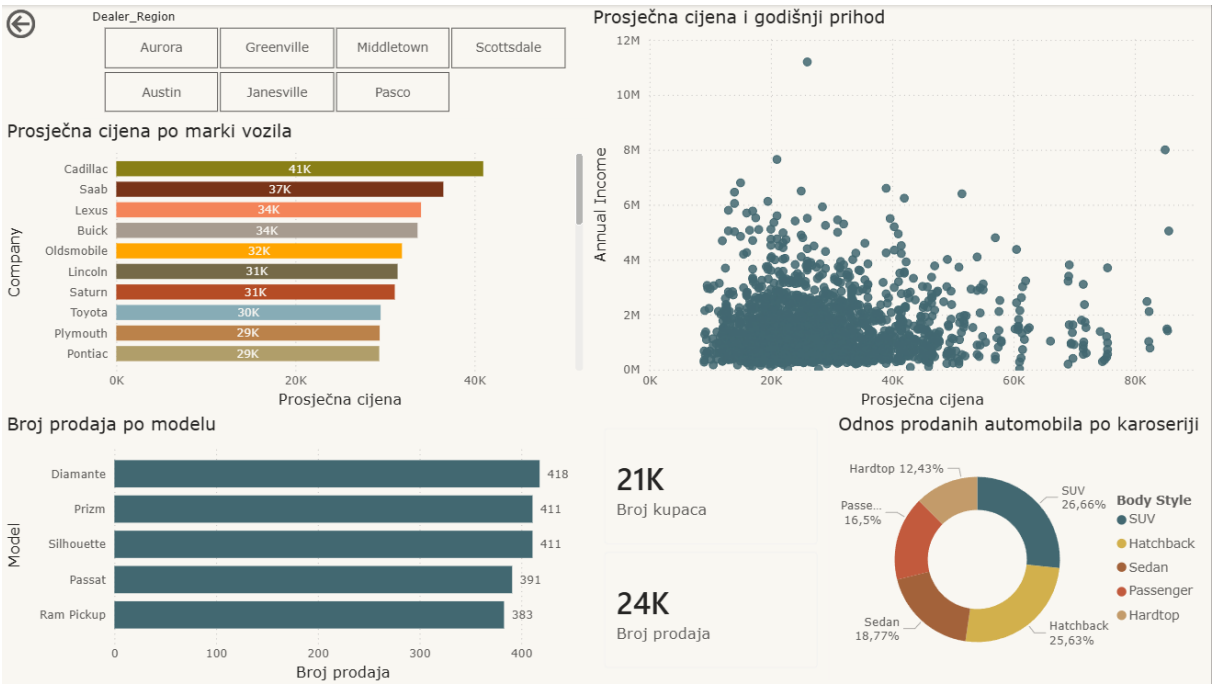


Slika 12: Analiza kupaca

Sljedeća analiza je analiza kupca. Ovdje se gleda koji spol više kupuje i koja grupa prihoda najviše kupuje i po kojoj prosječnoj cijeni. Kružni graf prikazuje odnos muškog i ženskog spola te odmah krajem su kartice sa prosječnom prodajnom cijenom vozila, prosječnim prihodom kupca i medijanom prihoda kupca. Desno od tih kartica je kombinirani graf gdje se kupci sortiraju po grupama prihoda i prikazuje se koja grupa prihoda kupuje najskuplje automobile. Dva grafa ispod prikazuju broj prodaja po prodavaču i spolu i zatim raspršeni graf koji prikazuje odnos cijena automobila sa godišnjim prihodom.

Kako se i na ovom izvješću mogu birati određeni podaci, ovdje možemo izabrati spol po želji i vidjeti **koje aute preferiraju** i u kojem **cjenovnom rasponu kupuju vozila**.

5.2.5. Cjenovna analiza



Slika 13: Cjenovna analiza

Ova stranica prikazuje cjenovnu analizu kroz četiri vizualna prikaza i dvije kartice. Prosječna cijena po marki vozila prikazuje prosječnu prodajnu cijenu automobila za svaku marku, direktno iznad se nalazi i filtar po regijama. Gore desno se nalazi prosječna cijena i godišnjih prihod u obliku raspšenog grafa. Broj prodaja po modelu prikazuje koji su modeli najčešće prodavani, točnije njih 5 najprodavanijih. Ovaj graf pomaže prepoznati najtraženije modele u prodajnom portfelju. Odnos prodanih automobila po karoseriji prikazuje raspodjelu prodaje prema tipu karoserije.

Ovom analizom može se dobiti **uvid u cjenovnu strukturu prodanih vozila**, **preferencije kupaca** te **zastupljenost pojedinih kategorija vozila**.

6. Zaključak

Izradom izvješća za analizu tržišta vozila omogućena je detaljna analiza prodaje, kupaca, geografskih obilježja tržišta i uspješnosti prodavača. Korištenjem različitih vizualizacija podaci su prikazani na pregledan i razumljiv način, što olakšava njihovu interpretaciju i donošenje poslovnih odluka.

Analiza omogućuje prepoznavanje najprodavanijih marki i modela vozila i praćenje trendova prodaje kroz vrijeme. Takvi rezultati analize pomoći poduzeću u prilagodbi prodajnih strategija, kao na primjer uvoz više onih vozila koja su najprodavanija. Na kraju, cilj projekta uspješno je ostvaren.

Popis literature

[1] Wikipedia. „Kaggle,” pogledano 30. svibnja 2026. adresa: https://en.wikipedia.org/wiki/Kaggle.

[2] W3Schools Team. „Pandas Introduction,” pogledano 30. svibnja 2026. adresa: https://www.w3schools.com/python/pandas/pandas_intro.asp.

[3] Microsoft Corporation. „What is Power BI?” Pogledano 30. svibnja 2026. adresa: https://learn.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview.

Popis slika

1. Sirovi podaci 4

2. Struktura Dimenzijske tablice dim_car 6
3. Struktura Dimenzijske tablice dim_dealer 6
4. Struktura Dimenzijske tablice dim_customer 7
5. Struktura Dimenzijske tablice dim_date 7
6. Činjenična tablica 8

7. Zvijezda shema u Power BI 9
8. Početno izvješće 10
9. Prodaja po marki vozila 10
10. Trend prodaje kroz vrijeme 11
11. Geografska analiza 12
12. Analiza kupaca 13
13. Cjenovna analiza 14

Popis tablica

1. Osnovne informacije o skupu podataka 3

Popis isječaka koda

1. Dodavanje i brisanje stupaca 5
2. Ispis df.info() 5
3. Ispitivanje duplikata 5
4. Ispitivanje duplikata 6
5. Dimenzijska tablica - dim_car 6
6. Dimenzijska tablica - dim_dealer 6
7. Dimenzijska tablica - dim_customer 7
8. Dimenzijska tablica - dim_date 7
9. Činjenična tablica - fact_sale 8